

LAPORAN DISKUSI

Skip data preparation dan dataset CSV
Proyek prediksi customer churn - folder simulation

Ringkasan eksekutif

Laporan ini merangkum fungsi **simulation/data_prep.py** serta isi empat CSV sumber dan tiga CSV hasil persiapan yang dibahas. Skip mengubah tabel pelanggan menjadi data fitur untuk latihan klasifikasi churn, menambahkan empat fitur turunan, lalu membagi seluruh 8.000 pelanggan menjadi data latih dan data uji.

1. Peran data_prep.py

Skip berada di folder **simulation** dan dirancang untuk menyiapkan data Kaggle bergaya e-commerce bagi latihan prediksi apakah pelanggan mengalami churn. Alur besarnya adalah membaca CSV, memeriksa kolom wajib, membuat fitur pelanggan, membagi data, lalu menyimpan dataset dan laporan kualitas.

? **Membaca sumber.** Memuat customers.csv, orders.csv, product_summary.csv, dan monthly_revenue.csv.

? **Validasi skema.** Memastikan kolom yang diperlukan ada. Jika ada yang hilang, proses berhenti dengan pesan kesalahan.

? **Membuat fitur.** Mengubah registration_date menjadi tanggal dan menghitung tenure serta rasio aktivitas pelanggan. Kolom kategori tetap berupa teks; encoding dilakukan oleh pipeline model agar tidak terjadi kebocoran informasi dari data uji ke data latih.

? **Membuat pembagian.** Membagi data pelanggan 80% train dan 20% test dengan random_state=42 serta stratify berdasarkan churned, sehingga proporsi kelas dijaga semirip mungkin.

? **Menyimpan hasil.** Menulis dataset model lengkap, train, test, dan laporan ringkas kualitas data dalam JSON.

Fitur turunan yang dihitung

Fitur	Makna	Cara hitung (ringkas)
customer_tenure_days	Lama pelanggan terdaftar hingga tanggal snapshot.	snapshot_date - registration_date, dalam hari; nilai negatif dibatasi ke 0.
orders_per_year	Perkiraan intensitas pesanan per tahun masa pelanggan.	total_orders dibagi lama masa pelanggan dalam tahun.
reviews_per_order	Ulasan per pesanan.	reviews_given / total_orders; jika pesanan nol hasilnya 0.
returns_per_order	Retur per pesanan.	returns_made / total_orders; jika pesanan nol hasilnya 0.

Tanggal snapshot ditentukan sebagai tanggal terbaru yang tampak pada order_date atau registration_date. Target churned dikonversi menjadi bilangan bulat.

2. Empat CSV sumber

Jumlah baris dan kolom berikut berasal dari berkas yang diperiksa di folder simulation. Baris header tidak dihitung sebagai data.

File	Ukuran	Isi utama
customers.csv	8.000 x 20	Satu baris per pelanggan; memuat identitas, demografi, ringkasan perilaku belanja, preferensi, serta label churn.
orders.csv	25.000 x 28	Satu baris per pesanan; detail transaksi, produk, waktu, pembayaran, pengiriman, status, retur dan aktivitas sesi.

File	Ukuran	Isi utama
product_summary.csv	140 x 9	Ringkasan agregat per produk dan kategori, termasuk pesanan, pendapatan, harga, rating, retur dan diskon.
monthly_revenue.csv	75 x 10	Ringkasan metrik per bulan: pesanan, pendapatan, diskon, retur, pelanggan unik dan pelanggan baru.

2.1 customers.csv

Kolom: customer_id, country, age, gender, membership_tier, registration_date, total_orders, total_spend_usd, avg_order_value_usd, days_since_last_purchase, preferred_category, preferred_device, preferred_payment_method, acquisition_channel, reviews_given, avg_review_score, returns_made, wishlist_items, newsletter_subscribed, churned.

File ini berada pada tingkat pelanggan (customer-level). Sebagian kolom menggambarkan karakteristik dan preferensi; sisanya merupakan ringkasan aktivitas. **churned** adalah label yang akan diprediksi. Nilai kolom ini dijadikan integer oleh skrip.

2.2 orders.csv

Kolom: order_id, customer_id, order_date, year, month, quarter, day_of_week, product_name, category, unit_price_usd, quantity, subtotal_usd, discount_pct, discount_amount_usd, shipping_fee_usd, tax_pct, tax_amount_usd, total_amount_usd, payment_method, device_used, delivery_days, delivery_date, order_status, returned, customer_rating, session_duration_minutes, pages_viewed_before_purchase, is_repeat_customer.

File ini berada pada tingkat transaksi: seorang pelanggan dapat muncul berkali-kali jika membuat banyak pesanan. Gunakan file ini untuk analisis detail transaksi, status pesanan, retur, nilai belanja dan proses sebelum pembelian. Skrip menggunakan sebagian kolomnya untuk validasi dan laporan kualitas.

2.3 product_summary.csv

Kolom: category, product_name, total_orders, total_revenue_usd, avg_price, avg_rating, return_rate, avg_discount_pct, avg_delivery_days.

Ini adalah ringkasan agregat per produk, bukan daftar transaksi mentah. Contohnya, satu baris merangkum jumlah order dan pendapatan suatu produk beserta rata-rata harga, rating, diskon, lama pengiriman, dan tingkat retur.

2.4 monthly_revenue.csv

Kolom: year, month, quarter, orders, revenue_usd, avg_order_value, avg_discount_pct, return_rate, unique_customers, new_customers.

Ini adalah ringkasan agregat per bulan. Setiap baris menggambarkan metrik pada periode bulan dan tahun tersebut, bukan pelanggan atau pesanan individual. Data yang diperiksa berjumlah 75 baris, dimulai dari Januari 2020. Dalam skrip, return_rate pada ringkasan bulanan dicatat bernilai nol karena ringkasan ini merepresentasikan pendapatan pesanan terkirim; untuk analisis retur, gunakan orders.csv.

3. CSV hasil persiapan model

Ketiga berkas ini berisi tabel fitur tingkat pelanggan. Semuanya memiliki 23 kolom yang sama: `customer_id`; tujuh fitur kategorikal; empat belas fitur numerik (sepuluh ringkasan asli dan empat fitur turunan); serta target `churned`.

Fitur kategorikal (7): `country`, `gender`, `membership_tier`, `preferred_category`, `preferred_device`, `preferred_payment_method`, `acquisition_channel`.

Fitur numerik dan turunan (14): `age`, `total_orders`, `total_spend_usd`, `avg_order_value_usd`, `days_since_last_purchase`, `reviews_given`, `avg_review_score`, `returns_made`, `wishlist_items`, `newsletter_subscribed`, `customer_tenure_days`, `orders_per_year`, `reviews_per_order`, `returns_per_order`.

Identitas dan target: `customer_id` dan `churned`.

File	Baris	Peran
customer_ml_dataset.csv	8.000	Seluruh data pelanggan hasil feature engineering, sebelum dipisah train/test.
customer_train.csv	6.400	Bagian 80% untuk melatih model dan mempelajari pola hubungan fitur dengan churn.
customer_test.csv	1.600	Bagian 20% untuk evaluasi model pada baris yang tidak digunakan saat pelatihan.

`customer_train.csv` dan `customer_test.csv` merupakan dua subset hasil pembagian `customer_ml_dataset.csv`. Pembagian dilakukan secara acak dengan seed tetap (`random_state=42`) dan stratifikasi target. Karena seed tetap, pembagian dapat direproduksi selama data sumber dan lingkungan pemrosesan tetap sama.

Kolom `customer_id` sengaja dipertahankan agar baris bisa ditelusuri ke data sumber. Dalam pemodelan, ID ini biasanya tidak dipakai sebagai fitur prediktif; fitur dan target ditentukan di pipeline model.

4. Hubungan antarberkas dan alur penggunaan

Empat berkas sumber memiliki tingkat rincian berbeda. `customers.csv` adalah dasar dataset model karena satu barisnya mewakili satu pelanggan dan menyediakan target `churned`. `orders.csv`, `product_summary.csv`, dan `monthly_revenue.csv` memberi detail serta ringkasan transaksi untuk pemeriksaan dan analisis. Skrip yang dibahas tidak menggabungkan agregasi dari tiga file tersebut ke fitur pelanggan; ia memvalidasi struktur sumber, membentuk fitur dari tabel `customers`, lalu menyimpan hasil model.

Alur keluaran: **`customers.csv` ? `customer_ml_dataset.csv` ? `customer_train.csv` + `customer_test.csv`**. Selain itu, skrip menghasilkan **`data_quality_report.json`**, yang merangkum jumlah baris, churn dan retur, nilai rating yang kosong, pendapatan, konsistensi ringkasan, tanggal snapshot, jumlah data train/test, dan jumlah fitur sebelum one-hot encoding.

5. Ringkasan

`customers.csv` menjawab ?siapa pelanggannya dan bagaimana ringkasan perilakunya?; `orders.csv` menjawab ?apa yang terjadi pada tiap transaksi?; `product_summary.csv` merangkum kinerja produk; `monthly_revenue.csv` merangkum kinerja per bulan. Adapun `customer_ml_dataset.csv` adalah tabel pelanggan lengkap yang telah ditambah fitur turunan, sedangkan `customer_train.csv` dan `customer_test.csv` adalah bagian latih dan evaluasinya.

Dokumen ini merangkum pembahasan mengenai folder `simulation`. Jumlah baris, nama kolom, dan contoh struktur merujuk pada berkas yang tersedia saat pemeriksaan.